

Rapport technique – Assistant intelligent de recommandation d'événements culturels

Table des matières


Rapport technique – Assistant intelligent de recommandation d'événements culturels	1
1. Objectifs du projet	2
2. Architecture du système	3
3. Préparation et vectorisation des données	4
4. Choix du modèle NLP	5
5. Construction de la base vectorielle	6
6. API et endpoints exposés	6
7. Évaluation du système	8
9. Organisation du dépôt GitHub	11
10. Annexes (exemples)	11

1. Objectifs du projet

- **Contexte** : Puls-Events, une entreprise technologique spécialisée dans la recommandation culturelle personnalisée, souhaite valider la faisabilité d'un assistant conversationnel capable de répondre aux questions des utilisateurs sur les événements culturels à venir.
- **Problématique** : En quoi un système RAG répond-il aux besoins métier ?
 1. Relier un modèle de langage à des données réelles
 2. Pertinent et fiable: réponses ancrées dans les données d'événements (moins d'hallucinations).
 3. Données à jour: ingestion OpenAgenda et index reconstruit à la demande.
 4. Flexible: gère requêtes multi-contraintes (lieu/date/prix/accessibilité).
 5. Personnalisable: préférences utilisateur intégrées facilement.
 6. Simple à tester/déployer: API /ask, Docker, métriques (Ragas) pour prouver la valeur.
- **Objectif du POC** : Démontrer la pertinence métier et la performance technique d'un chatbot RAG pour la recommandation d'événements, prêt à être étendu et déployé à plus grande échelle.
- **Périmètre** : Nous ciblons le département du var et restreindrons aux données de 2025 et 2026. Nous utilisons les données ouvertes d'événements publics OpenAgenda depuis OpenDatasoft
<https://public.opendatasoft.com/explore/assets/evenements-publics-openagenda/>

2. Architecture du système

- Schéma global



- Technologies utilisées :

- Containerisation et orchestration Docker et docker compose
 - Standard de l'industrie
 - Environnement maîtrisé, reproductible et facile à partager
- Base vectorielle : Faiss
 - Recherche de similarité à grande échelle
 - Bonnes Performances et faible latence
- NLP : Modèle Mistral (LLM)

- Génération contrôlée par contexte (via RAG) pour réduire les hallucinations
- Prompts guidés (prompt file)
- API : FastAPI
 - Rapide et standard dans sa mise en œuvre
 - Bonne communauté
 - Documentation et schémas OAS intégrée avec Swagger
- Evaluation et tests
 - Ragas et similarité pour mesurer pertinence, fidélité au contexte
 - Tests unitaires : ingestion, indexation
 - Tests E2E API

3. Préparation et vectorisation des données

- **Source de données** : API OpenDataSoft, données OpenAgenda, cf. README du projet pour configurer les variables d'environnement associées :

```
# --- OpenDataSoft (OpenAgenda) ---
OPENDATASOFT_URL=https://public.opendatasoft.com/api/explore/v2.1/catalog/datasets/evenements-publics-openagenda/records
FILTER_DEPARTMENT=Var
FILTER_YEARS=2025,2026# Format: "2024,2025,2026"
```

- **Nettoyage** :
 - Retrait des valeurs NaN : titre, description longue, date, etc.
- **Chunking** :
 - **Permet d'améliorer le rappel sémantique** : rechercher sur des blocs courts augmente la probabilité de récupérer précisément la portion pertinente plutôt que tout un document verbeux.
 - **Personnalisation / filtres**: attacher des métadonnées spécifiques par chunk (date, lieu, catégorie) pour des requêtes multi-contraintes plus efficaces.
 - **Taille** : 200 caractères / chunk

- **Overlap** : Permet la continuité entre les chunks : 50 caractères / chunk
- **Embedding** :
 - Modèle utilisé : paraphrase-multilingual-MiniLM-L12-v2
 - Adapté au français
 - Utilisation plus commode en environnement local (pas besoin de clé d'API, pas de difficultés de quotas)
 - On peut également envisager l'utilisation de Mistral embed qui est également adapté (attention plan et quotas à déterminer)
 - Dimensionnalité, logique de batch, format des vecteurs
 - 384 dimensions
 - Taille de batch à 128 (compromis utilisation mémoire)
 - Index IVF pour recherche rapide sur des grands volumes

4. Choix du modèle NLP

- **Modèle sélectionné** : Mistral LLM : mistral-medium
- **Pourquoi ce modèle** :
 - Souveraineté des données (modèle français)
 - Bonne qualité générale en français / anglais
 - Medium : compromis small & large (entre coût et pertinence)
 - Généralement plus économique que GPT, Claude
- **Prompting**: ChatPromptTemplate de LangChain
- **Limites du modèle** :
 - Contexte très long: accepte de grandes fenêtres, mais la qualité peut baisser à l'approche de la limite sans structuration :
 - Mitigation : RAG, chunking, résumé : pas bloquant dans notre cas
 - Risque d'hallucinations si le contexte est pauvre
 - Mitigation : fournir les données pertinentes au contexte lors de l'appel

5. Construction de la base vectorielle

- **Faiss utilisé**
- **Stratégie de persistance :**
 - Index.faiss + métadonnées packagées (.pkl) dans un volume (docker ici)
- **Métadonnées associées :**
 - Titre
 - Date
 - Lieu

6. API et endpoints exposés


- **Framework utilisé :** FastAPI
- **Endpoints clés :**
 - /ask : question utilisateur, réponse du système (public)
 - /rebuild : reconstruction de l'index
 - Privé, protégé par token API
- **Format des requêtes/réponses**
 - Communication bidirectionnelle en JSON
 - Verbes http selon contexte :
 - Rebuild : PUT
 - Ask : POST
 - Status : GET
- **Exemple d'appel API**

cURL ▾



```
1 curl --location 'http://127.0.0.1:8000/ask' \  
2 --header 'Content-Type: application/json' \  
3 --data '{"question": "je suis photographe amateur et je cherche  
des sorties photo de nature (oiseaux par exemple)" }'
```

- Tests effectués et documentés



Remarque : les tests évoluent avec le reste de la codebase, ils doivent être écrits de manière à s'auto-documenter (clarté du nom et des assertions)

- Gestion des erreurs / limitations

- Gestion des erreurs

- Validation avec pydantic

▼ 422 Validation Error

RESPONSE SCHEMA: application/json

→ detail ▼

Array of objects (Detail)

```
Array [
  {
    loc >
      required
    msg
      required
    type
      required
  }
]
```

loc >	required	Array of strings or integers (Location)
msg	required	string (Message)
type	required	string (Error Type)

- Exceptions côté python (envisager de logger et remonter en production, par exemple via Sentry)
- **Limitations**
 - Le endpoint /rebuild n'est accessible que par un administrateur (token API)
 - Pour ce POC il n'a pas été mis en place de limitation particulière ou quotas. Il est toutefois envisageable :
 - De gérer des quotas d'utilisation par adresse IP et par heure / jour / mois (par exemple), dans le cas d'un endpoint public comme actuellement
 - De rendre le endpoint semi-privé en demandant une authentification + assignation de quotas

7. Évaluation du système

- **Jeu de test annoté :**
 - Méthode d'annotation
 - Annotation manuelle avec définition de réponses de référence pour chaque question
 - Les réponses de référence spécifient les informations attendues (événement, date, lieu, horaires)
- **Métriques d'évaluation :**
 - RAGAS answer relevancy : score de pertinence de la réponse générée par rapport à la question (0 à 1)
 - Similarity Score : similarité sémantique entre la réponse générée et la réponse de référence (0 à 1)
- **Résultats obtenus :**
 - Analyse quantitative (scores globaux)
 - Score moyen relevancy : 0,79
 - Score moyen similarity : 0,73
 - Analyse qualitative (exemples de bonnes/mauvaises réponses)
 - Ollioules – événements musicaux printemps 2025

- RAGAS = 0,808 ; Similarity = 0,678
- Commentaire: la réponse répond bien à la question (pertinence élevée) mais diverge de la référence (événement précis attendu) → similarité plus basse.
- BD en mai 2025 (Var)
 - RAGAS = 0,707 ; Similarity = 0,674
 - Commentaire: bonne pertinence (la réponse reste liée à la question) mais n'identifie pas "La nuit de la BD" → similarité modérée.
- Job saisonnier 2025
 - RAGAS = 0,776 ; Similarity = 0,723
 - Commentaire: répertoire des forums/jobs pertinents (pertinence bonne), mais l'événement attendu à Hyères (10 mars) n'est pas mentionné.
- Visites guidées sciences/patrimoine (Toulon, sept. 2025)
 - RAGAS = 0,887 ; Similarity = 0,862
 - Commentaire: excellent alignement. L'élément attendu ("Le Muséum, entre science et fiction") est bien restitué.
- Expositions historiques La Valette (Journées du Patrimoine)
 - RAGAS = 0,752 ; Similarity = 0,737
 - Commentaire: l'exposition "Reliefs d'histoire" est citée (bonne pertinence) mais détails (horaires exacts) et formalisations différent → similarité légèrement moindre.

8. Recommandations et perspectives

- **Fonctionnement nominal validé**

Le chatbot comprend la question de l'utilisateur et répond en cohérence avec sa question. Les données présentes dans la base de données vectorielles sont bien utilisées dans les réponses, et de manière pertinente.

- **Limites du POC :**

- Risque de saturation de l'API Mistral

- Constat : malgré l'utilisation d'un abonnement payant (forfait d'entrée de gamme), l'API peut retourner l'erreur "Service tier capacity exceeded for this model".
- Mesures de mitigation : utiliser un autre service, ou prendre le plan supérieur
- Péremption des données temporelles
 - Constat : les données d'événements (à horizon court) deviennent rapidement obsolètes, dégradant la pertinence des réponses.
 - Mesures de mitigation : automatiser le processus de rebuild, envisager une mise à jour régulière, quotidienne ou hebdomadaire, par incréments notamment.
- **Améliorations possibles :**
 - Gestion multilingue
 - Constat : le corpus d'évènements est actuellement francophone, le chatbot pourrait être utilisé par des publics non francophones (ex : touristes anglophones)
 - Objectif : Permettre de poser des questions et répondre en anglais à minima. Le modèle utilisé étant multilingue c'est déjà possible pour l'embedding, toutefois le chatbot répond systématiquement en français actuellement.
 - Pistes : Détecter la langue et traduire la réponse. Traduire la requête si la recherche ne trouve rien
 - Changement de modèle
 - Actuellement le POC utilise un modèle multilingue, il en existe une multitude. Il peut être intéressant de comparer avec de nouveaux modèles et se tenir à jour sur des modèles qui pourraient être plus adaptés au domaine touristique par exemple

- Optimisation du traitement des données
 - Il est possible d'améliorer en continu le prétraitement des données issues d'OpenAgenda afin de mieux nettoyer, segmenter (chunker) et contextualiser les contenus avant leur indexation dans la base de données vectorielle.

9. Organisation du dépôt GitHub


Voir README.md.

10. Annexes (exemples)

- Extraits du jeu de test annoté

Question	Réponse
Quels événements musicaux sont programmés à Ollioules au printemps 2025 ?	La recherche doit faire ressortir « Concert du conservatoire avec Jean-Louis Ferrando » comme un événement musical en 2025 à Ollioules, au Jardin mistral à 21h
Je cherche des animations autour de la bande dessinée dans le var en mai 2025 Qu'est-ce qui est prévu ?	La recherche doit identifier « La nuit de la BD » comme une animation/rencontre BD le samedi 17 mai 2025 à Tourves, le samedi 17 mai de 15h à 23h
Montre-moi des événements utiles pour trouver un job saisonnier en 2025	La recherche doit remonter le « Forum emploi saisonnier », un forum de recrutement/orientation pour l'emploi saisonnier en 2025 à Hyères, le lundi 10 mars de 9h à 16h
Y a-t-il des visites guidées autour des sciences et du patrimoine en septembre 2025 à Toulon ?	La recherche doit proposer « Visites guidées – Le Museum entre science et fiction » comme visites guidées à thématique science/patrimoine en 2025, à Toulon le samedi 20 septembre 2025, au Jardin du Las.
Quelles expositions historiques sont visibles pour les journées du patrimoine à la Valette, fin septembre 2025 ?	La recherche doit retrouver « Exposition – Reliefs d'histoire » comme exposition à thématique historique/patrimoniale, le samedi 20 et dimanche 21 septembre 2025 de 11h à 18h à la Valette du Var.

- Prompt utilisé (ChatPromptTemplate)



- Extraits de logs ou exemples de réponse JSON

- Ask :

A screenshot of a REST client interface. At the top, there's a dropdown menu set to 'POST' and a text input field containing 'http://127.0.0.1:8000/ask'. To the right is a blue 'Send' button. Below this, there are tabs for 'Params', 'Auth', 'Headers (10)', 'Body', 'Scripts', and 'Settings'. The 'Body' tab is selected. Below the tabs, there's a dropdown menu set to 'raw' and another set to 'JSON'. To the right of these are links for 'Schema' and 'Beautify'. The main area shows a JSON request:

```
1 {"question": "il y a-t-il des concerts prévus à Toulon en juin 2025 ?" }
```

 Below this, there's a status bar showing '200 OK', '4.54 s', and '445 B'. To the right of this are icons for 'Save Response' and a menu icon. Below the status bar, there's a dropdown menu set to '{} JSON' and buttons for 'Preview' and 'Visualize'. To the right of these are icons for 'Copy', 'Share', and 'Print'. The main area shows a JSON response:

```
1 "Je ne connais qu'un seul événement musical à Toulon en juin 2025 :\n\n**Les couleurs du Portugal**\n- **Date** : 21 juin 2025\n- **Heure** : à partir de 20h\n- **Lieu** : Rue Castillon, 83000 Toulon\n- **Programme** : soirée avec musique et spécialités culinaires portugaises (bifanas, poulet grillé, etc.)."
```

POST http://127.0.0.1:8000/ask Send

Params Auth Headers (10) Body Scripts Settings Cookies

raw JSON Schema Beautify

```
1 {"question": "il y a-t-il des concerts prévus à Toulon en juin 2025 ?" }
```

Body 200 OK 4.54 s 445 B Save Response

{ } JSON Preview Visualize

```
1 "Je ne connais qu'un seul événement musical à Toulon en juin 2025 :\n\n**Les couleurs du Portugal**\n- **Date** : 21 juin 2025\n- **Heure** : à partir de 20h\n- **Lieu** : Rue Castillon, 83000 Toulon\n- **Programme** : soirée avec musique et spécialités culinaires portugaises (bifanas, poulet grillé, etc.)."
```

- Rebuild :

Body

200 OK

24.14 s

342 B



Save Response



{ } JSON

Preview

Visualize



```
1
2   "status": "success",
3   "message": "Index construit avec succès",
4   "details": {
5     "num_events": 646,
6     "num_chunks": 2828,
7     "avg_chunks_per_event": 4.38,
8     "embedding_model": "local:paraphrase-multilingual-MiniLM-L12-v2",
9     "dimension": 384
10  }
11
```