

Extrayez des données multimodales de sites web – Modèle de données Publication

Objectif du modèle

Le modèle **Publication** représente une entité générique et neutre permettant de structurer des données multimodales (texte + image + autres médias) provenant de différentes sources (Fakeddit, API News, Reddit, etc.).

Identifiant (id)

Le champ **id** correspond à l'identifiant natif fourni par la source d'origine. Il ne s'agit pas d'un identifiant global du système, mais de l'identifiant interne de la publication dans sa source (ex: id Reddit, id article API, etc.).

Champs principaux

- **source** : nom de la source des données.
- **title** : texte principal de la publication.
- **fake** : variable cible binaire (true = fake news, false = real).
- **image_url** : URL de l'image associée (si présente).

Champs optionnels

Les champs suivis d'un '?' dans le diagramme sont optionnels et peuvent ne pas être présents selon la source :

- content
- image_url
- document_url
- video_url
- author

Ce modèle permet d'assurer un format neutre, extensible et cohérent pour l'ensemble des datasets intégrés au pipeline.

Diagramme du modèle :

Publication

- +String id
- +String source
- +String title
- +Bool fake
- +String content?
- +String image_url?
- +String document_url?
- +String video_url?
- +String author?